

Relatório Atualizado - Diagnóstico de Câncer de Mama

Disciplina: A.I - Machine Learning

Grupo 5: Rayssa Gomides Marconato (RA 2001130) e Samara Adorno (RA 2001639).

Projeto P2, continuidade da P1, com notebook revisado, modelo salvo e aplicação Streamlit.

1. Objetivo


O objetivo do projeto é classificar tumores de mama como benignos ou malignos a partir de características numéricas extraídas de exames citológicos. O problema é de classificação binária e foi tratado com pipelines de Machine Learning para garantir reprodutibilidade.

2. Melhorias em relação à P1

A devolutiva da P1 indicou três pontos principais: criar divisão em treino, validação e teste; apresentar tabela comparativa com métricas numéricas consolidadas; fortalecer a análise com seleção de features e EDA mais detalhada. A versão final incorpora esses pontos, mantendo Pipeline sklearn, StandardScaler, StratifiedKFold, curvas ROC, matriz de confusão e interpretação clínica dos erros.

3. Dataset e EDA

Foi usado o Breast Cancer Wisconsin, com 569 amostras e 30 características preditoras. A EDA mostrou maior quantidade de casos benignos, justificando estratificação nas divisões. Variáveis ligadas a raio, perímetro, área, concavidade e pontos côncavos apresentam forte relação com malignidade.



4. Metodologia


As colunas sem valor preditivo foram removidas, a variável-alvo foi codificada como maligno = 1 e benigno = 0, e os dados foram separados em treino, validação e teste com estratificação. Os modelos foram treinados com Pipeline contendo StandardScaler, SelectKBest e classificador. A otimização usou GridSearchCV com StratifiedKFold de 5 folds, usando F1 como métrica principal.


5. Tabela comparativa de métricas

Modelo	Conjunto	Acurácia	Precisão	Recall	F1	AUC
SVM	Validacao inicial	0.9649	0.9756	0.9302	0.9524	0.9921
RandomForest	Validacao inicial	0.9737	0.9762	0.9535	0.9647	0.9921
NaiveBayes	Validacao inicial	0.9386	0.9091	0.9302	0.9195	0.9823
SVM	Validacao otimizada	0.9649	0.9535	0.9535	0.9535	0.9957
SVM	Teste final	0.9825	0.9762	0.9762	0.9762	0.9960
RandomForest	Validacao otimizada	0.9737	0.9762	0.9535	0.9647	0.9903
RandomForest	Teste final	0.9649	1.0000	0.9048	0.9500	0.9974
RandomForest	Teste final após retreino	0.9561	1.0000	0.8810	0.9367	0.9936

6. Modelo final

O modelo final escolhido foi RandomForest. A escolha considerou desempenho de validação e equilíbrio entre F1, recall e AUC. Após a escolha, o pipeline foi retreinado com treino + validação e salvo em model/modelo_final.joblib, o mesmo arquivo carregado pela aplicação Streamlit.






7. Features importantes

A seleção de features fortalece a interpretação do modelo ao destacar variáveis mais informativas. No contexto biológico, características como área, perímetro, raio e pontos côncavos estão associadas a tamanho, forma e irregularidade celular.

Feature	Importance
worst perimeter	0.1662
worst radius	0.1529
worst area	0.1242
worst concave points	0.1160
mean concave points	0.0908
mean concavity	0.0625
mean area	0.0492
mean radius	0.0437
mean perimeter	0.0384
worst symmetry	0.0200



8. Interpretação clínica

Em oncologia, falsos negativos são mais críticos porque um caso maligno previsto como benigno pode atrasar investigação e tratamento. Falsos positivos também importam, pois podem gerar ansiedade e procedimentos desnecessários, mas em um sistema de triagem a prioridade tende a ser reduzir falsos negativos sem perder completamente a precisão.

9. Limitações

O projeto é acadêmico e não substitui diagnóstico médico. O dataset é controlado, relativamente pequeno e não representa toda a variabilidade clínica real. Para uso prático, seriam necessárias validação externa, avaliação prospectiva, calibração de probabilidades e acompanhamento por especialistas.

10. Conclusão

A versão P2 apresenta evolução metodológica em relação à P1, com divisão correta dos dados, métricas consolidadas, EDA ampliada, seleção de features, modelo salvo e aplicação Streamlit funcional. O resultado final é coerente entre notebook, relatório, modelo e app.